

Criando sistemas de recomendação com Python Scikit-Surprise

José Fernando Tavares
Booknando Livros



JOSÉ FERNANDO TAVARES



JFTavares

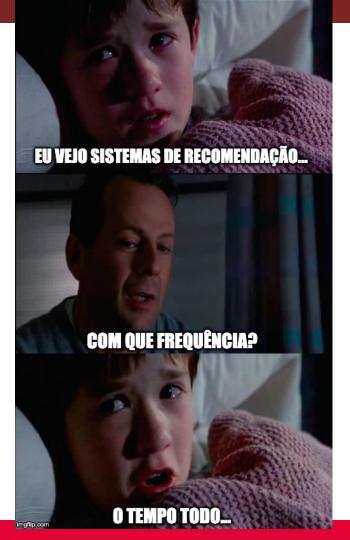


fernando@booknando.com.br

- Formação humanista (filosofia e Teologia)
- Especialista em livros digitais
- Consultor de acessibilidade
- Cursando mestrado Ciência da Computação
- Cursando MBA em tecnologia para negócios
- Apaixonado por Python



booknando.com.br



Everywhere

surprose

A Python scikit for recommender systems.

Home

Documentation

C) GitHub page

★ Star 🖁 Fork

Maintained by Nicolas Hug Page built with Jekyll and Hyde

SCIKIT-SURPRISE

Overview

Surprise is a Python scikit building and analyzing recommender systems.

Surprise was designed with the following purposes in mind:

- Give users perfect control over their experiments. To this end, a strong emphasis is laid on documentation, which we
 have tried to make as clear and precise as possible by pointing out every detail of the algorithms.
- Alleviate the pain of Dataset handling. Users can use both built-in datasets (Movielens, Jester), and their own custom datasets.
- Provide various ready-to-use prediction algorithms such as baseline algorithms, neighborhood methods, matrix factorization-based (SVD, PMF, SVD++, NMF), and many others. Also, various similarity measures (cosine, MSD, pearson...) are built-in.
- · Make it easy to implement new algorithm ideas.
- Provide tools to evaluate, analyse and compare the algorithms performance. Cross-validation procedures can be run
 very easily using powerful CV iterators (inspired by scikit-learn excellent tools), as well as exhaustive search over a
 set of parameters.

Scikit Surprise

Surprise é um add-on SciPy para construir e analizar sistemas de recomendação baseados em filtragem colaborativa

© Copyright 2015, Nicolas Hug.

Comunidade ativa no Github

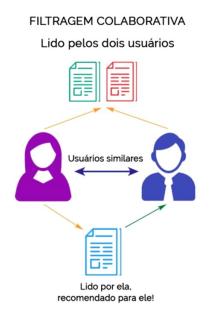
Licença BSD 3-Clause

Paradigmas suportados



Filtragem colaborativa







Documentação muito completa

Matrix Factorization-based algorithms

class surprise.prediction_algorithms.matrix_factorization.SVD

Bases: surprise.prediction_algorithms.algo_base.AlgoBase

The famous SVD algorithm, as popularized by Simon Funk during the Netflix Prize. When baselines are not used, this is equivalent to Probabilistic Matrix Factorization [SM08] (see note below).

The prediction \hat{r}_{ui} is set as:

$$\hat{r}_{ui} = \mu + b_u + b_i + q_i^T p_u$$

If user u is unknown, then the bias b_u and the factors p_u are assumed to be zero. The same applies for item i with b_i and q_i .

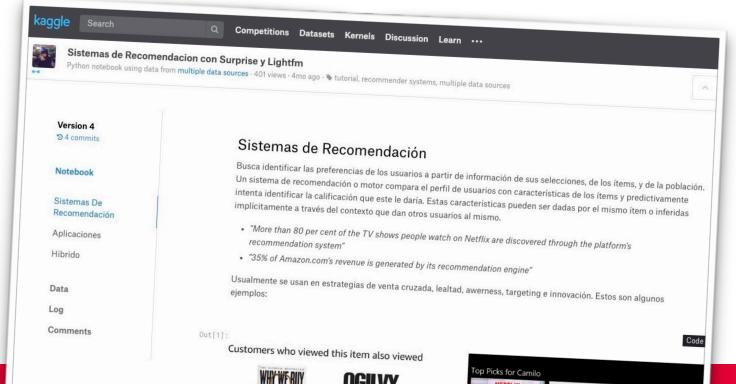
For details, see equation (5) from [KBV09]. See also [RRSK10], section 5.3.1.

To estimate all the unknown, we minimize the following regularized squared error:

unknown, we minimize the following the
$$\sum_{r_{ui} \in R_{train}} \left(r_{ui} - \hat{r}_{ui}\right)^2 + \lambda \left(b_i^2 + b_u^2 + ||q_i||^2 + ||p_u||^2\right)$$



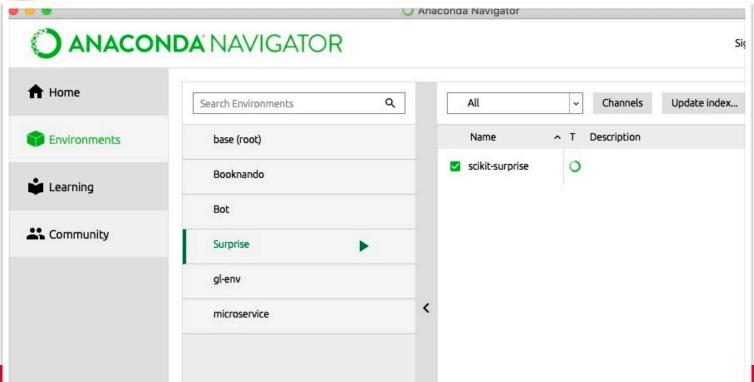
Excelente para uso acadêmico ou em âmbitos de estudos dos algoritmos





Fácil de Instalar

\$ pip install scikit-surprise



```
from future import (absolute import, division,
print function, unicode literals)
from surprise import SVD
from surprise import Dataset
from surprise import accuracy
from surprise.model_selection import train test split
data = Dataset.load builtin('ml-1m')
trainset, testset = train test split(data, test size=.15)
algoritmo = SVD(n epochs=20)
algoritmo.fit(trainset)
uid = str(103)
iid = str(1499)
pred = algoritmo.predict(uid, iid, r_ui=1, verbose=True)
test pred = algoritmo.test(testset)
print("Avaliação RMSE: ")
accuracy.rmse(test pred, verbose=True)
print("Avaliação MAE: ")
accuracy.mae(test_pred, verbose=True)
```



Fácil de Usar



Matrix factorization-based

SVD

SVD++

NMF

Neighborhood methods (KNN)

KNNBasic

KNNWithMeans

KNNWithZScore

SlopeOne

Co-Clustering



Cosine

$$cosine_sim(i,j) = \frac{\sum_{u \in U_{ij}} r_{ui} \cdot r_{uj}}{\sqrt{\sum_{u \in U_{ij}} r_{ui}^2} \cdot \sqrt{\sum_{u \in U_{ij}} r_{uj}^2}}$$

MSD

$$msd(i,j) = \frac{1}{|U_{ij}|} \cdot \sum_{u \in U_{ij}} (r_{ui} - r_{uj})^2$$

Pearson

pearson_sim(i, j) =
$$\frac{\sum_{u \in U_{ij}} (r_{ui} - \mu_i) \cdot (r_{uj} - \mu_j)}{\sqrt{\sum_{u \in U_{ij}} (r_{ui} - \mu_i)^2} \cdot \sqrt{\sum_{u \in U_{ij}} (r_{uj} - \mu_j)^2}}$$

Flexibilidade dos dados de entrada



Possui base de dados já implementado (MovieLens, Jester)
Muito simples adicionar ou usar outra entrada de dados



Não possui ferramentas para preparar os dados de entrada

```
1 from surprise import SVD
 from surprise import Dataset
  from surprise.model selection import cross validate
 # Load the movielens-100k dataset (download it if needed),
  data = Dataset.load builtin('ml-100k')
8
 # We'll use the famous SVD algorithm.
 algo = SVD()
 # Run 5-fold cross-validation and print results
 cross validate(algo, data, measures=['RMSE', 'MAE'], cv=5,
  verbose=True
   In [1]: (executing file "svd exemplo.py")
   Dataset ml-100k could not be found. Do you want to download it? [Y/n] Y
   Trying to download dataset from http://files.grouplens.org/datasets/movielen
   s/ml-100k.zip...
   Done! Dataset ml-100k has been saved to C:\WinPy3702\settings/.surprise data
   /ml-100k
           ing DMCC MAC of algorithm CVD on E colit(a)
```



Possui um módulo que facilita a criação de novos algoritmos

```
From file examples/building_custom_algorithms/most_basic_algorithm.py
 from surprise import AlgoBase
 from surprise import Dataset
 from surprise.model selection import cross validate
 class MyOwnAlgorithm(AlgoBase):
     def __init__(self):
         # Always call base method before doing anything.
         AlgoBase. init (self)
     def estimate(self, u, i):
         return 3
 data = Dataset.load builtin('ml-100k')
 algo = MyOwnAlgorithm()
 cross validate(algo, data, verbose=True)
```



Possui três metodologia de avaliação a RMSE, a MAE e a FCP

```
# Run 5-fold cross-validation and print results
cross_validate(algo, data, measures=['RMSE', 'MAE'], cv=5,
verbose=True)
```



Evaluating RMSE, MAE of algorithm SVD on 5 split(s).

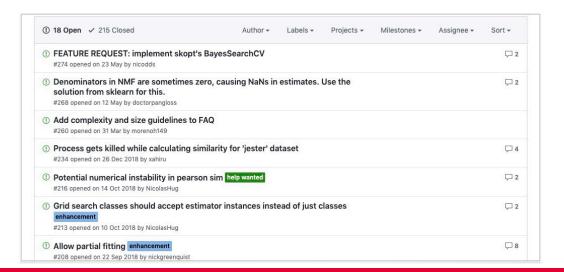
	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Mean	Std
RMSE (testset)	0.9408	0.9403	0.9275	0.9279	0.9426	0.9358	0.0067
MAE (testset)	0.7439	0.7400	0.7281	0.7358	0.7401	0.7376	0.0054
Fit time	4.35	4.40	4.36	4.36	4.35	4.37	0.02
Test time	0.14	0.12	0.16	0.11	0.11	0.13	0.02



Excelente Documentação



O suporte é dado apenas pela documentação e pela página do GitHub





Não possui ferramenta específica para esparsidade de dados



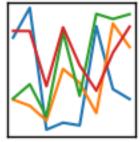


Não possui ferramenta específica para lidar com grande quantidade de dados.

pandas $y_{it} = \beta' x_{it} + \mu_i + \epsilon_{it}$

$$y_{it} = \beta' x_{it} + \mu_i + \epsilon_{it}$$









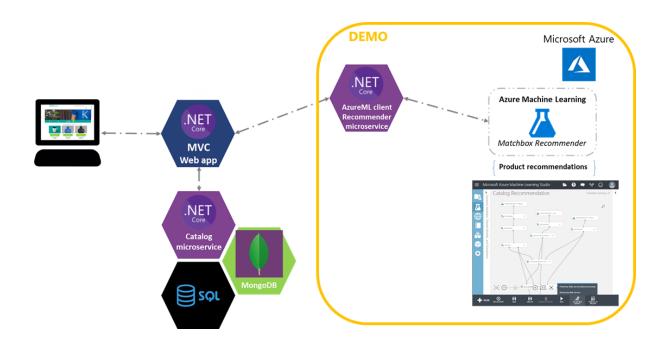
Alguns algoritmos possuem um desempenho baixo







Não foi pensado para ambiente de produção

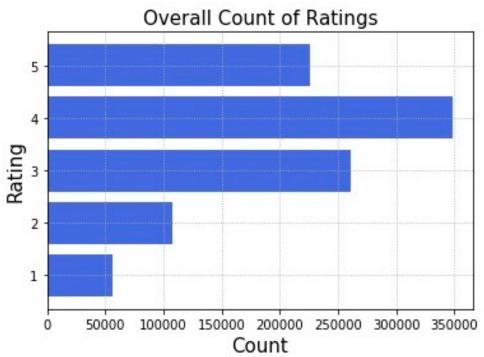


SCIKIT-SURPRISE

Brincando com o Movielens

Movie Lens 1M

6.040 usuários **3.706** filmes **1.000.209** avaliações



Movielens 1M	RMSE	MAE	Time
SVD++	0,862	0,672	6:12:38
SVD	0,874	0,686	0:05:28
k-NN Baseline	0,895	0,706	0:16:39
Slope One	0,907	0,715	0:08:23
Co-Clustering	0,916	0,718	0:01:59
Baseline	0,909	0,719	0:00:38
NMF	0,917	0,725	0:05:31
k-NN	0,923	0,727	0:15:11
k-NN With Means	0,929	0,738	0:16:02
Random	1.506	1.207	0:00:36



Rating Alto: ID 49, idade entre 18 e 24 anos, programador e mora em Huston no Texas (USA). Ele deu um rating alto (4) para o filme The Negotiator (1998), um filme de ação Ação e Thriller



Rating Baixo: ID 103

idade entre 45 e 49 anos

um executivo/manager com que mora em San Diego.

Ele avaliou com um rating baixo (1) o filme

Anaconda (1997), um filme de ação/aventura/Thriller

```
from future import (absolute import, division, print function,
                       unicode literals)
from surprise import KNNBasic
from surprise import Dataset
from surprise import accuracy
from surprise.model selection import train test split
# Load the movielens-100k dataset UserID::MovieID::Rating::Timestamp
data = Dataset.load builtin('ml-1m')
trainset, testset = train_test_split(data, test_size=.5)
```

```
algoritmo = KNNBasic(k=50, sim_options={'name': 'pearson',
'user based': True, 'verbose': True})
algoritmo.fit(trainset)
uid = str(49)
iid = str(2058)
pred = algoritmo.predict(uid, iid, r_ui=4, verbose=True)
```

```
# run the trained model against the testset
test pred = algoritmo.test(testset)
# Avalia RMSE
print("Avaliação RMSE: ")
accuracy.rmse(test_pred, verbose=True)
# Avalia MAE
print("Avaliação MAE: ")
accuracy.mae(test_pred, verbose=True)
```

```
Predição de avaliação:
user: 49 item: 2058
```

```
(Booknando) MacBookBooknando:recommenderSystem josefernandotavares$ python KNNWithMean
s single.py
Usando o algoritmo KNNWithMeans com 50 vizinhos
Algoritmo de similiraridade: Pearson
Computing the pearson similarity matrix...
Done computing similarity matrix.
Predição de avaliação:
ossible': False}
Avaliação RMSE:
RMSE: 0.9736
Avaliação MAE:
MAE: 0.7751
(Booknando) MacBookBooknando:recommenderSystem josefernandotavares$
```

r ui = 4.00

est = 3.55

SVD++

Para Rating ALTO:

User	Item	r_ui	est	Epochs	Test	RMSE	MAE
49	2058	4	3,52	20	0,15	0,8583	0,6693
49	2058	4	3,68	5	0,15	0,8854	0,6974
49	2058	4	3,62	5	0,15	0,888	0,7002

SVD++

Para Rating Baixo:

User	Item	r_ui	est	Epochs	Test	RMSE	MAE
103	1499	1	2,62	20	0,15	0,8583	0,6693
103	1499	1	3,06	5	0,15	0,867	0,6806
103	1499	1	3,08	5	0,15	0,8878	0,7

KNNWithMeans

Para Rating alto:

Use r	Item	r_ui	est	actual_k	Test	Av.RMSE	Av.MAE
49	2058	4	3,76	40	0,15	0,9132	0,7184
49	2058	4	3,66	40	0,15	0,9159	0,7208
49	2058	4	3,77	30	0,15	0,9215	0,7263
49	2058	4	3,9	30	0,15	0,9237	0,728
49	2058	4	3,9	10	0,15	0,957	0,7548
49	2058	4	3,69	10	0,15	0,9575	0,7549
49	2058	4	3,39	10	0,15	0,9578	0,7563

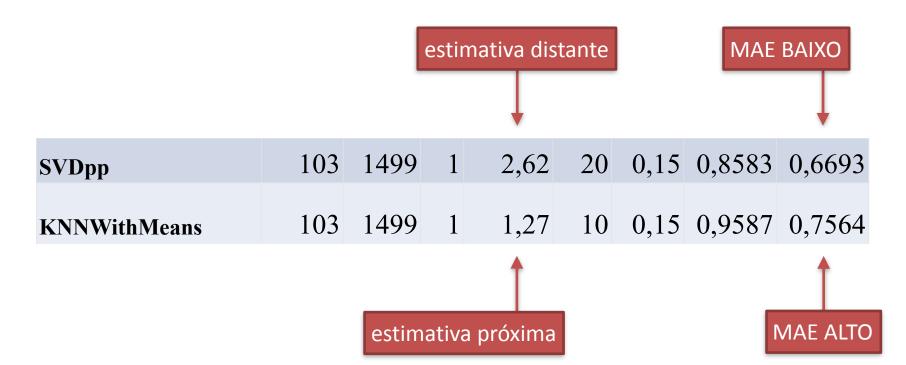
KNNWithMeans

Para Rating Baixo:

User	Item	r_ui	est	actual	Test	Av.RMS	Av.MAE
				_k		E	
103	1499	1	1,63	10	0,15	0,9592	0,7564
103	1499	1	1,27	10	0,15	0,9587	0,7564
103	1499	1	1,84	10	0,15	0,959	0,757

KNNWithMeans X SVDpp

para Rating Baixo:



SVD

Para Rating alto:

User	Item	r_ui	est	Epochs	Test	Av.RMS E	Av.MAE
49	2058	4	3,48	10	0,15	0,8874	0,7003
49	2058	4	3,72	10	0,15	0,8874	0,7015
49	2058	4	3,53	10	0,15	0,8883	0,7017
49	2058	4	3,6	5	0,15	0,9115	0,7233
49	2058	4	3,56	5	0,15	0,9128	0,7237
49	2058	4	3,49	5	0,15	0,9145	0,7246

Slope One

Para Rating alto:

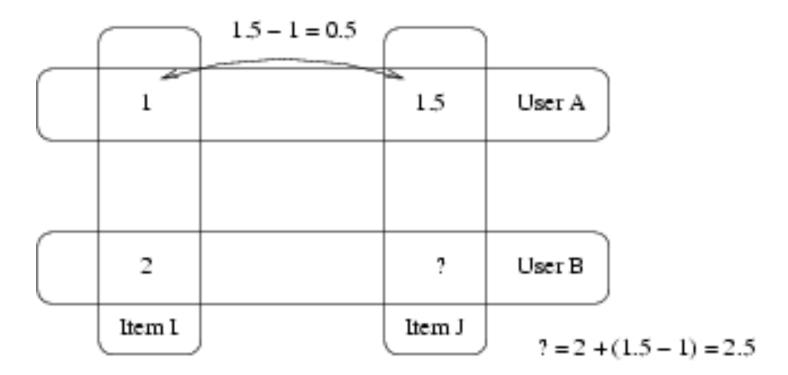
User	Item	r_ui	est	Test	Av.RMSE	Av.MAE
49	2058	4	3,54	0,15	0,9029	0,7126
49	2058	4	3,48	0,15	0,9064	0,7146
49	2058	4	3,55	0,15	0,9079	0,716

Slope One

Para Rating Baixo:

103	1499	1	3,09	0,15	0,9047	0,7128
103	1499	1	2,99	0,15	0,906	0,7146
103	1499	1	3,01	0,15	0,9049	0,7131

Slope One



É importante entender bem o conjunto de dados e como cada algoritmo interage com eles. É provável que um mesmo algoritmo que deu bons resultados neste conjunto de dados pode não dar os mesmos resultados com outro.

O **scikit-surprise** se demonstrou uma boa ferramenta para o estudo dos algoritmos e estudos off-line de dataset.

Mesmo com poucos conhecimento de Python é possível iniciar a estudar os algoritmos por trás dos sistemas de recomendação.

OBRIGADO!



https://github.com/JFTavares/recommenderSystem

